

Instrucciones para el evaluador

Calidad de la retroalimentación generada sobre pares de código

Qué vas a hacer

Vas a calificar una serie de textos breves. Cada texto justifica por qué dos fragmentos de código se parecen o no se parecen entre sí. Los textos fueron producidos por distintos sistemas automáticos, pero tú no sabes cuál escribió cada uno, y ese desconocimiento forma parte del diseño del estudio: no intentes deducirlo ni comentarlo con nadie mientras calificas.

Tu tarea no es decidir si la conclusión del texto es correcta. Tu tarea es juzgar la calidad de la argumentación con la que llega a ella. Esta distinción es la más importante de todo el documento y conviene que la tengas presente en cada fila.

Cómo trabajar

Abre el archivo que se te ha entregado en una hoja de cálculo. Cada fila es un texto independiente. Las columnas `codigo_a` y `codigo_b` indican los dos archivos de código que el texto compara: ábrelos y léelos antes de puntuar, porque el primer criterio exige comprobar si lo que el texto afirma sobre ese código es verdad.

Puntúa cada fila en los cuatro criterios de la sección siguiente, escribiendo un número entero de 0 a 100 en la columna correspondiente. La columna `comentario` es opcional; úsala cuando una puntuación necesite explicación, y sobre todo cuando detectes una afirmación falsa sobre el código.

Los cuatro criterios

Criterio	Qué se pregunta
CORRECCIÓN	¿Lo que el texto afirma sobre el código es verdadero? Comprueba cada afirmación contra los dos archivos. <i>0</i> = contiene afirmaciones falsas o inventadas. <i>100</i> = todo lo que afirma es verificable en los archivos.
ESPECIFICIDAD	¿Se refiere a elementos concretos de estos archivos, o podría aplicarse a cualquier par de códigos? <i>0</i> = serviría igual para cualquier otro par. <i>100</i> = solo tiene sentido para este par en particular.
EXPLICACIÓN	¿Explica <i>por qué</i> , o solo enuncia <i>qué</i> ? <i>0</i> = puro enunciado, sin razonamiento visible. <i>100</i> = razonamiento trazable de principio a fin.
UTILIDAD	¿Le serviría a un estudiante para entender el veredicto sin ayuda adicional? <i>0</i> = no le aporta nada. <i>100</i> = es suficiente por sí sola.

Cómo usar la escala

Usa el rango completo de 0 a 100. Si todo te parece un 80, la escala no está midiendo nada y el estudio no podrá distinguir entre sistemas. Reserva los extremos para cuando corresponda, pero úsalos: el 0 y el 100 existen.

Como referencia aproximada, considera que por debajo de 20 está lo que es directamente deficiente, entre 40 y 60 lo que cumple sin destacar, y por encima de 80 lo que a ti te parecería difícil de mejorar. No es una regla, solo un ancla para que tu escala no se comprima hacia el centro.

Cuatro cosas que no debes hacer

1. **No califiques el veredicto.** Si el texto concluye que dos códigos son muy parecidos y a ti te parece que no lo son, eso no baja la nota de EXPLICACIÓN. Un texto puede razonar de forma impecable hacia una conclusión equivocada, y en ese caso debe puntuar alto en argumentación y bajo en corrección solo si además afirma cosas falsas sobre el código. El acierto del veredicto se mide aparte, en otra parte del estudio.
2. **No premies la extensión.** Un texto breve y preciso puede merecer un 100. Uno largo, bien redactado y vago debe puntuar bajo. La longitud no es un criterio.
3. **No compares filas entre sí.** Cada fila se puntúa sola, contra los criterios, no contra las demás. No busques coherencia entre tus propias puntuaciones ni intentes repartir notas.
4. **No consultes con el otro evaluador.** La concordancia entre ambos es uno de los resultados del estudio. Si os ponéis de acuerdo antes o durante, esa medida se destruye y el trabajo pierde su valor.

Sobre el archivo de clave. Junto a tu hoja existe un archivo que asocia cada texto con el sistema que lo escribió. No lo abras hasta haber entregado tus puntuaciones. Conocer el origen de los textos introduciría un sesgo que invalidaría tu trabajo, aunque hicieras el esfuerzo consciente de ignorarlo.

Al terminar

Guarda el archivo con tu identificador de evaluador, tal como se te haya indicado, por ejemplo `hoja_E1.csv` o `hoja_E2.csv`. Consérvalo en formato CSV con codificación UTF-8; si tu hoja de cálculo ofrece otras opciones al guardar, elige esa.

Si has dejado alguna fila sin puntuar, indícalo al entregar en lugar de rellenarla a ojo. Una fila vacía se gestiona sin problema en el análisis; una puntuación puesta por compromiso, no.

Gracias por el tiempo dedicado. Estas puntuaciones son la única referencia humana del estudio y de ellas depende que el resto de las mediciones automáticas puedan interpretarse.